Лабораторна робота 6

Побудова ETL-конвеєра на основі веб-даних та API

Мета роботи

Набути практичних навичок отримання даних із різнорідних джерел, їх перетворення та інтеграції, організації ETL-конвеєра, використання формату Parquet для зберігання підготовлених даних та формування аналітичних показників.

Завдання

1. Отримання даних (Extract)

1. Обрати відкритий веб-сайт, який містить інформацію про товари та їх ціни.
2. За допомогою Python та однієї з бібліотек `BeautifulSoup`, (`Scrapy` або `Selenium`) отримати дані про товари.
3. Сформувати набір даних, який містить щонайменше такі атрибути:
    - назва товару;
    - категорія;
    - ціна;
    - валюта;
    - дата отримання даних.
4. Отримати дані про курси валют за допомогою API НБУ, ExchangeRate-API, Open Exchange Rates або іншого відкритого API.
5. Зберегти отримані з веб-сайту та API початкові дані у форматі CSV або JSON у каталозі `raw/`.

---

2. Перетворення та інтеграція даних (Transform)

1. Виконати базову перевірку отриманих даних:
    - видалити дублікати;
    - перевірити наявність пропущених значень у ключових полях;
    - привести ціни та курси валют до числового типу;
    - привести дати до формату `datetime`.
2. За допомогою `pandas` об'єднати інформацію про товари з відповідними курсами валют.
3. Для кожного товару розрахувати його вартість у **трьох різних валютах**, наприклад:

   UAH → USD → EUR

4. Додати до результуючого набору даних нові атрибути з розрахованими цінами.
5. Перевірити коректність результатів перерахунку валют.

У результаті етапу Transform повинен бути сформований єдиний структурований набір даних, придатний для подальшої аналітичної обробки.

---

3. Завантаження даних (Load)

1. Створити каталог `processed/` для збереження результатів ETL-процесу.
2. Зберегти підготовлений набір даних у двох форматах:
   - CSV;
   - Parquet.
3. Повторно завантажити створені CSV та Parquet файли за допомогою `pandas`.
4. Порівняти:
   - розмір CSV та Parquet файлів;
   - типи даних після повторного завантаження;
   - час читання файлів.
5. Зробити висновок щодо переваг та недоліків використання CSV і Parquet для зберігання підготовлених аналітичних даних.

Структура даних після виконання ETL може мати вигляд:

```
project/
│
├── raw/
│   ├── products.csv
│   └── exchange_rates.json
│
├── processed/
│   ├── products_processed.csv
│   └── products_processed.parquet
│
└── etl.py
```

---

4. BI-аналітика

На основі набору даних із каталогу `processed/` виконати базову аналітичну обробку.

Розрахувати щонайменше **три аналітичні показники**, наприклад:

- середню та медіанну ціну товарів за категоріями;
- мінімальну та максимальну ціну товарів у кожній категорії;
- кількість товарів у різних цінових діапазонах;
- частку товарів кожної категорії у загальному наборі;
- різницю між середніми цінами різних категорій;
- найдорожчі товари у кожній категорії.

Результати аналітики подати у вигляді окремих підсумкових таблиць.

---

5. Візуалізація результатів

За допомогою `matplotlib`, `seaborn`, Power BI або Tableau побудувати **три різні графіки**, які відображають результати проведеної аналітики.

Візуалізації повинні передавати інформацію про структуру та закономірності у даних, наприклад:

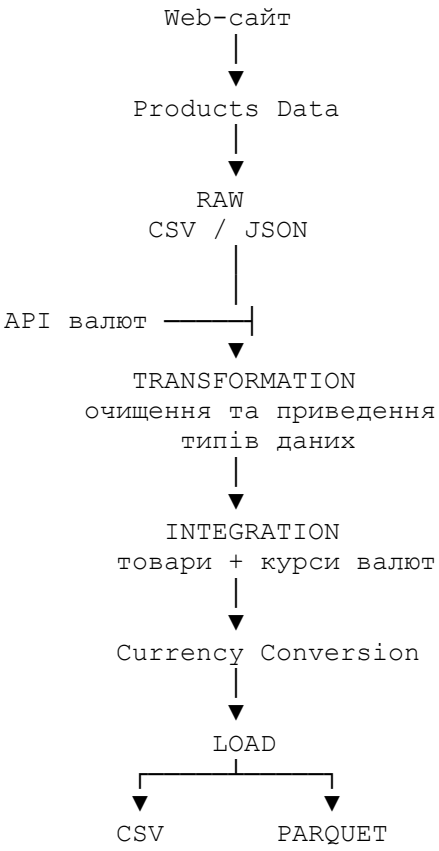
- порівняння цін між категоріями;
- структуру товарів за ціновими діапазонами;
- співвідношення середньої, мінімальної та максимальної ціни;
- розподіл цін товарів.

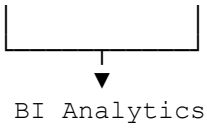
Графіки повинні містити назви, підписи осей, легенду за необхідності та бути зрозумілими без додаткового аналізу програмного коду.

---

6. Представлення ETL-конвеєра

Побудувати схему реалізованого процесу обробки даних:





Для кожного етапу схеми коротко вказати, які операції виконуються на етапах **Extract, Transform та Load**.
