Лабораторна робота № 7

Інкрементальна обробка та відстеження змін у даних

Мета роботи

Набути практичних навичок інкрементальної обробки даних: поділу даних на часові пакети, послідовної обробки нових порцій даних, оновлення результуючої таблиці, відстеження змін та перевірки правильності інкрементальної обробки шляхом порівняння з результатами повної обробки набору даних.

Вхідні дані

Використати набір даних про покупки клієнтів за певний період часу. Один покупець може зустрічатися у наборі багато разів, оскільки кожний рядок описує окрему покупку або позицію транзакції.

Завдання

1. Первинна підготовка даних

1. Завантажити початковий набір даних у `pandas DataFrame`.
2. Визначити:
    - кількість записів та ознак;
    - типи даних;
    - кількість унікальних покупців;
    - кількість унікальних транзакцій.
3. Перетворити `purchase_date` у формат `datetime`.
4. Перевірити дані на наявність пропущених значень та дублікатів.
5. Створити поле:

```
amount = quantity * unit_price
```

яке характеризує вартість покупки.

2. Формування часових пакетів даних

Відсортувати початковий набір за `purchase_date` та розділити його на **три послідовні часові періоди**:

```
transactions_period_1.csv
transactions_period_2.csv
transactions_period_3.csv
```

Періоди не повинні перетинатися за датами.

Надалі вважати, що дані надходять до системи поступово: спочатку доступні лише дані першого періоду, пізніше — другого, а потім третього.

3. Початкове завантаження — Initial Load

Обробити `transactions_period_1.csv`.

На основі транзакцій першого періоду сформувати звітну таблицю покупців:

```
customers_current.csv
```

Один покупець повинен бути представлений **одним рядком**.

Для кожного `customer_id` розрахувати:

```
customer_id
number_of_purchases
total_quantity
total_spent
last_purchase_date
```

де:

- `number_of_purchases` — кількість покупок покупця;
- `total_quantity` — загальна кількість придбаних одиниць товару;
- `total_spent` — загальна сума покупок;
- `last_purchase_date` — дата останньої покупки.

Зберегти отриману таблицю як початковий стан `customers_current.csv`.

4. Інкрементальна обробка другого періоду

Завантажити **лише** `transactions_period_2.csv`.

Для покупців цього періоду розрахувати ті самі агреговані характеристики.

Порівняти `customer_id` з таблицею `customers_current.csv` та визначити:

- **нових покупців** — `customer_id`, яких ще немає в таблиці;
- **існуючих покупців** — `customer_id`, які вже присутні в таблиці.

Для нових покупців виконати **INSERT** — додати нові рядки.

Для існуючих покупців виконати **UPDATE**:

```
number_of_purchases += нові покупки
total_quantity += нова кількість товарів
total_spent += нова сума
last_purchase_date = max(попередня дата, нова дата)
```

Зберегти оновлений стан `customers_current.csv`.

5. Інкрементальна обробка третього періоду

Аналогічно обробити `transactions_period_3.csv`.

При цьому **не виконувати повторну обробку `transactions_period_1.csv` та `transactions_period_2.csv`.**

Визначити нових та існуючих покупців, виконати відповідні операції INSERT та UPDATE і сформувати фінальний стан `customers_current.csv`.

Таким чином, результуюча таблиця формується послідовно:

```
Period 1 → Initial Load
              ↓
      customers_current
              ↓
Period 2 → INSERT / UPDATE
              ↓
      customers_current
              ↓
Period 3 → INSERT / UPDATE
              ↓
      customers_current
```

6. Ведення журналу обробки

Створити файл:

```
processing.log
```

У ньому для **кожного періоду** зафіксувати:

- назву обробленого файлу;
- часовий діапазон даних;
- кількість отриманих транзакцій;
- кількість унікальних покупців у новому пакеті;
- кількість нових покупців;
- кількість покупців, для яких оновлено показники;

- загальну кількість покупців у `customers_current.csv` після обробки;
- дату і час виконання обробки.

Наприклад:

```
Period 2
File: transactions_period_2.csv
Transactions processed: 1250
Customers in batch: 430
New customers: 75
Updated customers: 355
Customers after processing: 1280
Status: SUCCESS
```

7. Перевірка повної та інкрементальної обробки

Виконати **контрольну повну обробку** початкового набору даних.

Сформувати таблицю покупців без інкрементальної обробки:

```
customers_full
```

Окремо маємо результат послідовної обробки:

```
customers_incremental
```

Порівняти:

```
customers_full
        ↕
customers_incremental
```

Перевірити:

- однакову кількість покупців;
- однаковий набір `customer_id`;
- `number_of_purchases`;
- `total_quantity`;
- `total_spent`;
- `last_purchase_date`.

Результати повної та інкрементальної обробки повинні **збігатися**.

8. Сформувати звіт про зміни

На основі `processing.log` сформувати невеликий підсумковий звіт, наприклад:

Період	Транзакцій	Нових покупців	Оновлено покупців	Покупців після обробки
Period 1	...	...	–	...
Period 2	...	...	...	...
Period 3	...	...	...	...

Зробити висновок про те, **як змінювалася результуюча таблиця після надходження кожної нової порції даних**.

9. Зробити висновок

У висновку пояснити різницю між **Full Processing** та **Incremental Processing** і відповісти на питання:

Чому при надходженні нових даних доцільніше обробляти тільки новий фрагмент, а не повторно весь накопичений набір даних?